

Note méthodologique

Modèle E5

Adrien MAYSOUNABE

Septembre 2024

Table des matières

1	Introduction	2
2	Jeu de données	2
2.1	Échantillon	2
2.2	Caractéristiques	2
3	Concept de l'algorithme	3
3.1	Introduction	3
3.2	Structure du modèle	3
3.2.1	Fonctionnement d'un dual-encoder	3
3.2.2	Pré-entraînement contrastif	3
3.3	Conclusion	4
4	Modélisation	4
4.1	Analyse comparative des modèles	4
4.1.1	RoBERTa	4
4.1.2	T5	4
4.1.3	USE	4
4.2	Méthodes de classification	4
4.2.1	KMeans	4
4.2.2	LogisticRegression	4
4.2.3	RandomForestClassifier	5
4.3	Métriques	5
4.3.1	Adjusted Rand Index	5
4.3.2	Accuracy Score	5
4.3.3	F1-score (Macro)	5
5	Résultats	5
5.1	Synthèse de l'analyse comparative	5
5.2	Visualisation des métriques	6
5.3	Performances du modèle E5 _{large}	7
6	Limites et améliorations	8
6.1	Limites	8
6.1.1	Taille du jeu de données	8
6.1.2	Prétraitement des données	8
6.2	Améliorations	8
6.2.1	Augmentation de la taille du jeu de données	8
6.2.2	Optimisation des modèles	8
6.2.3	Fine Tuning	8
7	Conclusion	8
8	Références	8

1 Introduction

L'entreprise anglophone **Place de marché** lance une plateforme de e-commerce. Les vendeurs proposent des articles en postant une photo, ainsi qu'une description.

- La catégorie d'un article est effectuée manuellement par le vendeur
- Le nombre d'articles présentés sur la plateforme est peu conséquent

Afin de faciliter la mise en ligne de nouveaux articles et rendre la recherche de produits la plus fluide possible, il devient nécessaire d'automatiser cette tâche d'attribution de la catégorie.

Problématiques :

- Attribution des catégories manuelle donc peu fiable
- Augmentation du nombre d'articles au fil du temps

Objectif : Automatiser la tâche d'attribution de la catégorie à l'aide de la description du produit.

2 Jeu de données

2.1 Échantillon

Data — Observation 0	
Attribut	Valeur
uniq_id	55b85ea15a1536d46b7190ad6fff8ce7
crawl_timestamp	2016 - 04 - 30 03 : 22 : 56 +0000
product_url	http ://www.flipkart.com/...
product_name	Elegance Polyester Multicolor Abstract Eyelet Door Curtain
product_category_tree	["Home Furnishing >> Curtains & Accessories >> ...]
pid	CRNEG7BKMFFYHQ8Z
retail_price	1899.0
discounted_price	899.0
image	55b85ea15a1536d46b7190ad6fff8ce7.jpg
is_FK_Advantage_product	False
description	Key Features of Elegance Polyester Multicolor ...
product_rating	No rating available
overall_rating	No rating available
brand	Elegance
product_specifications	{ "product_specification" $\Rightarrow$ [{ "key" $\Rightarrow$ "Brand", ... } , ...] }

2.2 Caractéristiques

Les variables considérées ici sont :

- **uniq_id** $\rightarrow$ Identifiant unique du produit
- **product_category_tree** $\rightarrow$ Catégorie d'un produit (Principale > Secondaire > Tertiaire ...)
- **description** $\rightarrow$ La description d'un produit

Pour les catégories, on ne considèrera que la catégorie principale qui sont très équilibrés (cf figure ci-dessous)




FIGURE 1 – Répartition des articles par catégorie principale

3 Concept de l’algorithme

3.1 Introduction

Le modèle **E5** est un modèle d’embedding textuel développée par Microsoft en 2023. Il est conçu pour générer des représentations vectorielles de haute qualité.

3.2 Structure du modèle

La structure du modèle **E5** repose sur une architecture de type **dual-encoder**, utilisant un encodeur **Transformer** pré-entraîné.

La spécificité du modèle réside dans l’utilisation de paires de textes, chacune constituée d’une requête (q) et d’un passage (p).

3.2.1 Fonctionnement d’un dual-encoder

Un **dual-encoder** fonctionne avec deux types de textes, une requête q et un passage p . Chaque texte est traité par un encodeur **Transformer** pour les transformer en vecteurs denses capturant les caractéristiques sémantiques et contextuelles du texte.

Une fois les deux textes encodés, le **dual-encoder** calcule une mesure de similarité entre les deux embeddings définie par

$$s(q, p) = \frac{E_q \cdot E_p}{\|E_q\| \|E_p\|}$$

où E_q et E_p sont les embeddings respectifs des textes q et p .

3.2.2 Pré-entraînement contrastif

Lors de l’entraînement, le modèle apprend à maximiser la similarité entre ces paires tout en minimisant la similarité avec des passages non pertinents.

L’objectif est d’apprendre à distinguer les paires de textes pertinentes des non pertinentes, afin de rapprocher les embeddings sémantiquement liés tout en éloignant ceux qui ne le sont pas.

Pour cela, le modèle utilise une fonction de perte appelée **InfoNCE**(Information Noise Contrastive Estimation) définie par

$$L_{\text{cont}} = -\frac{1}{n} \sum_{i=1}^n \log \frac{e^{s(q_i, p_i)}}{e^{s(q_i, p_i)} + \sum_j e^{s(q_i, p_{ij}^-)}}$$

où :

- $s(q_i, p_i)$ est la similarité normalisée entre les textes p_i et q_i
- p_{ij}^- représente les passages négatifs associés au texte q_i

3.3 Conclusion

Le modèle **E5** représente une avancée significative dans le domaine des embeddings textuels. Son architecture **dual-encoder** ainsi que sa fonction de perte **InfoNCE** lui permettent de produire des embeddings qui capturent efficacement les nuances sémantiques tout en écartant les passages non pertinents. Ces spécificités font d'**E5** un modèle fiable qui surpasse de nombreux modèles existants, tant dans des contextes zéro-shot que lors d'entraînements avec des données étiquetées. Enfin, il se distingue encore par un nombre de paramètres beaucoup moins élevé que celui d'autres modèles, ce qui le rend plus efficient en termes de ressources.

4 Modélisation

4.1 Analyse comparative des modèles

Dans cette partie, une description trois modèles de traitement du langage qui ont servi de référence pour évaluer les performances du modèle **E5** dans notre contexte.

4.1.1 RoBERTa

RoBERTa (Robustly Optimized BERT Pretraining Approach) est un modèle développé par Facebook AI en 2019, qui s'appuie sur l'architecture BERT. Contrairement à son prédécesseur, RoBERTa a été pré-entraîné avec un plus grand volume de données et utilise des techniques d'entraînement améliorées, telles que la suppression de la tâche de prédiction de mots masqués. Ce modèle est particulièrement efficace pour les tâches de compréhension du langage et a montré des performances exceptionnelles dans plusieurs benchmarks de NLP.

4.1.2 T5

Le modèle T5 (Text-to-Text Transfer Transformer), développé par Google Research en 2019, introduit une approche novatrice qui transforme toutes les tâches de NLP en un format de type "texte-à-texte". Cela signifie que tant les entrées que les sorties sont traitées comme des chaînes de texte, permettant une grande flexibilité dans les applications. T5 a été formé sur un large éventail de tâches, le rendant particulièrement adaptable.

4.1.3 USE

L'Universal Sentence Encoder (USE) est un modèle conçu pour générer des embeddings de phrases qui capturent le sens sémantique des textes. Développé par Google, il utilise une approche basée sur le Transformer pour encoder des phrases de manière à ce qu'elles puissent être utilisées dans des tâches de similarité textuelle, de classification et de recherche. USE est particulièrement adapté pour les applications nécessitant des embeddings rapides et de haute qualité.

4.2 Méthodes de classification

Dans cette partie, une description rapide des méthodes utilisées pour la classification des produits.

4.2.1 KMeans

L'algorithme KMeans est un algorithme de clustering non supervisé qui cherche à partitionner un ensemble de données en un nombre de clusters prédéfini, noté k . Il fonctionne en minimisant la variance intra-cluster, en assignant chaque point à son centre le plus proche.

Nous avons 7 catégories donc `n_clusters = 7`.

4.2.2 LogisticRegression

La régression logistique est un modèle de classification supervisé qui utilise une fonction logistique pour prédire la probabilité d'appartenance d'un exemple à une classe donnée. C'est un modèle simple mais très efficace, en particulier pour des données linéairement séparables.

Ici, nous avons fixé les paramètres suivants :
$$\begin{cases} C = 0,1 \\ \text{max_iter} = 1000 \end{cases}$$

4.2.3 RandomForestClassifier

Le RandomForestClassifier est un modèle d'apprentissage supervisé basé sur des forêts d'arbres décisionnels. Il fonctionne en construisant plusieurs arbres de décision sur des sous-échantillons du dataset et en prenant la moyenne des prédictions pour améliorer la généralisation et réduire le risque de surapprentissage.

Ici, nous avons fixé le nombre d'arbres à 200 (`n_estimators = 200`)

4.3 Métriques

Pour évaluer la performance des modèles dans notre pipeline de classification et de clustering, nous avons choisi trois métriques principales :

- Adjusted Rand Index (ARI)
- Accuracy
- F1-Score macro

4.3.1 Adjusted Rand Index

L'Adjusted Rand Index est une métrique utilisée pour évaluer la qualité d'un clustering en comparant les clusters obtenus à une partition de référence (les vrais labels dans notre cas). L'ARI tient compte du fait que certaines similarités peuvent apparaître par hasard. Ainsi, l'ARI mesure la proportion de paires de points correctement classées ou non classées dans le même cluster en fonction du hasard, et ce, tout en tenant compte des proportions des classes. L'ARI est donc une mesure adaptée pour évaluer la capacité des modèles à retrouver la structure des classes tout en évitant de surévaluer les performances en cas de prédictions aléatoires.

4.3.2 Accuracy Score

L'accuracy est une métrique classique en classification supervisée, mesurant la proportion de prédictions correctes parmi l'ensemble des observations. En d'autres termes, elle évalue le rapport entre le nombre de classifications correctes et le total des observations. Dans notre cas, avec 7 classes équilibrées, l'accuracy est particulièrement pertinente, car elle n'est pas biaisée par des déséquilibres de classe, comme cela peut être le cas dans d'autres contextes. L'accuracy est une mesure simple et facilement interprétable, ce qui en fait un choix courant dans les tâches où les classes sont bien définies et équilibrées.

4.3.3 F1-score (Macro)

Le F1-score est une métrique qui combine la précision (proportion des prédictions correctes parmi celles effectuées) et le rappel (proportion des prédictions correctes parmi les observations réelles). C'est une métrique harmonisée qui est particulièrement utile lorsque l'on souhaite évaluer la capacité d'un modèle à éviter les faux positifs et les faux négatifs.

Dans notre étude, nous utilisons le F1-score macro, qui calcule le F1-score pour chaque classe individuellement, puis en fait la moyenne. Cette version macro du F1-score est appropriée pour notre dataset équilibré en 7 classes, car elle donne un poids égal à chaque classe, même si leur fréquence est la même. Cela permet de garantir que le modèle performe bien sur toutes les classes et ne privilégie pas certaines classes au détriment d'autres.




5 Résultats

5.1 Synthèse de l'analyse comparative

Modèle	KMeans			Random Forest			Logistic Regression		
	ARI	ACC	F1	ARI	ACC	F1	ARI	ACC	F1
USE	0,45	0,68	0,67	0,68	0,84	0,84	0,51	0,74	0,74
RoBERTa	0,21	0,41	0,40	0,46	0,71	0,71	0,21	0,41	0,38
T5	0,11	0,33	0,33	0,43	0,69	0,69	0,09	0,32	0,27
E5_{base} (v2)	0,28	0,48	0,47	0,66	0,83	0,83	0,29	0,45	0,41
E5_{large} (v2)	0,36	0,55	0,55	0,71	0,86	0,87	0,29	0,48	0,45

TABLE 1 – Synthèse des résultats

5.2 Visualisation des métriques



5.3 Performances du modèle E5_{large}




FIGURE 2 – Vrais labels vs labels prédits par Random Forest Classifier




FIGURE 3 – Matrice de confusion pour les classes 0 à 6

6 Limites et améliorations

6.1 Limites

6.1.1 Taille du jeu de données

Les analyses ont été réalisées sur un jeu de données relativement petit, ce qui peut affecter la généralisation des résultats. Un échantillon plus conséquent pourrait nous permettre d'obtenir des résultats plus significatifs.

6.1.2 Prétraitement des données

Bien que les descriptions aient été prétraitées via un processus de nettoyage, il est possible que ce dernier ne soit pas optimal et que d'autres techniques ou méthodes de prétraitement puissent améliorer la qualité des données, et par conséquent, les performances des modèles.

6.2 Améliorations

6.2.1 Augmentation de la taille du jeu de données

L'intégration de données supplémentaires, via des techniques de data augmentation ou de l'acquisition de données provenant de sources externes, permettrait d'enrichir considérablement le jeu de données. Cela permettrait non seulement d'augmenter la diversité des exemples d'entraînement, mais également d'améliorer la capacité des modèles à généraliser à de nouvelles situations. Une plus grande variété de données aiderait à réduire le risque de surapprentissage et à renforcer la robustesse des modèles face à des données inédites, conduisant ainsi à des performances plus fiables dans des scénarios réels.

6.2.2 Optimisation des modèles

Dans cette étude, les tests ont été réalisés uniquement avec le prétraitement PCA + t-SNE, et les modèles ont été évalués avec des paramètres par défaut afin de comparer les différentes méthodes d'embedding. Cependant, l'exploration d'autres techniques de prétraitement pourrait améliorer les performances des modèles. De même, l'intégration de la validation croisée permettrait une évaluation plus robuste et fiable des résultats. Résumé des résultats et perspectives pour des travaux futurs.

6.2.3 Fine Tuning

Ici, le modèle **E5** a été utilisé tel quel. Le fine-tuning du modèle permettrait de l'adapter au contexte, ce qui améliorerait sa capacité à capturer les subtilités du langage, et donc, ses performances.

7 Conclusion

Cette étude a évalué l'efficacité de différentes méthodes d'embedding pour la classification de données textuelles. Bien que les modèles utilisant PCA et t-SNE aient donné des résultats satisfaisants, des améliorations sont possibles.

Les limites liées au choix du prétraitement et à l'utilisation de paramètres par défaut suggèrent qu'une exploration de diverses techniques de prétraitement et d'optimisation des hyperparamètres pourrait renforcer les performances. De plus, le fine-tuning de modèles pré-entraînés, comme E5, pourrait également améliorer significativement les résultats en les adaptant aux spécificités des données.

En résumé, cette étude offre des insights précieux sur les méthodes d'embedding tout en ouvrant des pistes pour des recherches futures visant à améliorer encore les performances des modèles.

8 Références

Page GitHub – E5 Text Embeddings

Lien disponible ici

Multilingual E5 Text Embeddings – *Février 2024*

Lien disponible ici

Improving Text Embeddings with Large Language Models – *Mai 2024*

Lien disponible ici

Page HuggingFace – **e5-large-v2**

Lien disponible ici

From Word Embeddings to Pre-Trained Language Models :

A State-of-the-Art Walkthrough – *September 2022*

Lien disponible ici