

Projet n°8

Réalisation d'un dashboard et assurance d'une
veille technique

PRÊT À DÉPENSER

OPENCLASSROOMS

Sommaire

- Introduction
- Conception du dashboard
 - Informations client
 - Nuage de points
 - Analyse de prédiction
- Veille technique
 - Présentation du modèle
 - Analyse comparative
 - Présentation des résultats
 - Limites et améliorations
- Conclusion

INTRODUCTION

Missions et objectifs

L'objectif de la société **Prêt à dépenser** est de permettre aux chargés de relation client d'expliquer les décisions d'octroi de crédit de manière transparente.

De plus, la société aimerait se mettre à jour sur des techniques de data science dans le domaine du NLP.

Les missions ici sont :

- Pour le dashboard interactif
 - Intégration de données permettant d'expliquer les prédictions
 - Permettre la modification des données client
 - Intégration de graphiques permettant de situer le client par rapport aux autres
- Pour la veille technique
 - Recherche et choix d'un modèle récent à évaluer
 - Réaliser une analyse comparative du modèle

CONCEPTION DU DASHBOARD

Présentation

Contexte et récapitulatif


- Chaque client est identifié grâce à son `SK_ID_CURR`
- Aucun doublon dans les données
- Imputation par la moyenne avec `SimpleImputer`
- Encodage des variables catégorielles avec `OneHotEncoder`
- Pipeline de prédiction $\rightarrow \begin{cases} \text{StandardScaler} \\ \text{XGBClassifier} \end{cases}$
- Optimisation du coût à l'aide d'un score de performance
- API de prédiction déployée via `Render`

Interface

Structure de l'Application :

- **Menu de navigation :**
 - Informations clients
 - Analyse graphique
 - Analyse prédictive
- **Sélection client :**

Menu déroulant permettant de sélectionner un client via son identifiant.



Informations clients

Cette partie permet de :

- Afficher les informations essentielles du client sélectionné
- Pouvoir les enregistrer au format .csv
- Modifier les informations à l'aide de sliders
- Mettre à jour les informations

ID du client actuel : 100001

Informations clients

Âge	Nombre d'enfants	Revenus totaux (en k€)	Années travaillées	Prix du bien	Taux de remboursement
52	0	135	6	450	4

Modification des informations client

Âge

18 52 100

Nombre d'enfants

0 0 20

Revenus totaux (k€)

0 135 500

Années travaillées

0 6 52

Prix du bien (k€)

0 450 1000

Taux de remboursement (%)


0 4 30

Mettre à jour les informations du client

Analyse graphique

Cette partie permet à l'utilisateur de visualiser les données des variables les plus influentes sur la probabilité de faillite.


De plus, le client sélectionné est mis en valeur afin qu'il soit possible de le distinguer des autres.



Analyse prédictive

Cette partie permet à l'utilisateur de visualiser la probabilité de faillite, exprimée en pourcentage.

Elle permet également de visualiser les variables ayant contribué à la hausse ou la baisse de cette probabilité prédite.



VEILLE TECHNIQUE

Modèle E5

Présentation

Le modèle E5 est un modèle basé sur Transformer développé par **Microsoft** en 2023.

Ce modèle, similaire à d'autres comme BERT se distingue par quelques améliorations.

Architecture
de type
Dual-Encoder

Pré-
entraînement
contrastif


Entraînement
sur de
grandes bases
de données

Dual-Encoder

Le Dual-Encoder fonctionne avec deux types de textes :

Requête q & Passage p

- Traitement indépendant de q et p via leurs encodeurs respectifs.
- Récupération des embeddings E_q et E_p
- Calcule la similarité entre les deux embeddings (cosinus)



Pré-entraînement contrastif

Objectifs :

- Rapprocher les paires de textes similaires
- Éloigner les paires de textes différents

Pour cela, le modèle E5 utilise la fonction de perte InfoNCE (**Info Noise Contrastive Estimation**) définie mathématiquement par

$$\mathcal{L}_{\text{cont}} = -\frac{1}{n} \sum_{i=1}^n \log \frac{e^{s(q_i, p_i)}}{e^{s(q_i, p_i)} + \sum_j e^{s(q_i, p_{ij}^-)}}$$



Analyse comparative

Résultats

Modèles	Métriques	Classifieurs
RoBERTa	ARI Score	KMeans
USE	Accuracy	RandomForest
T5	F1—Score	LogisticRegression



Modèle	KMeans			Random Forest			Logistic Regression		
	ARI	ACC	F1	ARI	ACC	F1	ARI	ACC	F1
USE	0,45	0,68	0,67	0,68	0,84	0,84	0,51	0,74	0,74
RoBERTa	0,21	0,41	0,40	0,46	0,71	0,71	0,21	0,41	0,38
T5	0,11	0,33	0,33	0,43	0,69	0,69	0,09	0,32	0,27
E5 _{base} (v2)	0,28	0,48	0,47	0,66	0,83	0,83	0,29	0,45	0,41
E5 _{large} (v2)	0,36	0,55	0,55	0,71	0,86	0,87	0,29	0,48	0,45

Visualisation



Modèle E5_{large}


Résultats de la classification



Légende

- | | |
|-------------------|----------------------------|
| ● Baby Care | ● Beauty and Personal Care |
| ● Computers | ● Home Decor Festive Needs |
| ● Home Furnishing | ● Kitchen Dining |
| ● Watches | |

Matrice de confusion



Bilan

Le modèle E5 a réalisé de meilleures performances que les autres modèles avec lesquels il a été comparé.

Méthode

- Modèle $\rightarrow$ E5_{large} v2
- Classifieur $\rightarrow$ RandomForest
- Preprocessing $\rightarrow$ PCA + T-SNE

Performances

- ARI $\rightarrow$ 0,71
- Accuracy $\rightarrow$ 0,86
- F1 $\rightarrow$ 0,87

Limites

L'analyse réalisée admet quelques limites à considérer lors de l'interprétation des résultats.

- Taille du jeu de données relativement faible
- Prétraitement des données (nettoyage + transformation)
- Optimisation des hyperparamètres des classifieurs
- Fine-tuning du modèle

CONCLUSION

Conclusion

Dashboard

Le dashboard a été conçu pour être accessible aux utilisateurs. Les fonctionnalités sont segmentées et accessibles via un menu.

De plus, il permet de :

- Visualiser et modifier les informations clients
- Visualiser les données à l'aide de nuages de points
- Afficher la probabilité de faillite
- Visualiser les caractéristiques contribuant le plus à la prédiction



Lien vers l'application `Streamlit`

Veille technique

Plusieurs modèles ont été comparés au modèle sélectionné afin d'évaluer ses performances dans le cadre d'une analyse comparative.

- Prétraitement unique (nettoyage)
- Preprocessing identique (PCA + t-SNE)
- Hyperparamètres des classifieurs fixés
- Pas de fine-tuning

Les limites liées à ces choix suggèrent que de meilleures performances sont possibles.

Références

- Page GitHub — E5 Text Embeddings
Lien disponible ici
- Multilingual E5 Text Embeddings — *Février 2024*
Lien disponible ici
- Improving Text Embeddings with Large Language Models — *Mai 2024*
Lien disponible ici
- Page HuggingFace — e5-large-v2
Lien disponible ici
- From Word Embeddings to Pre-Trained Language Models : A State-of-the-Art Walkthrough — *September 2022*
Lien disponible ici

FIN